Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

Riešenie úloh strojového učenia využitím Kubernetes

Bakalárska práca

2022 **Štefan Hadbavný**

Technická univerzita v Košiciach
Fakulta elektrotechniky a informatiky

Riešenie úloh strojového učenia využitím Kubernetes

Bakalárska práca

Študijný program:	Informatika
Študijný odbor:	9.2.1. Informatika
Školiace pracovisko:	Katedra počítačov a informatiky (KPI)
Školiteľ:	Marek Ružička
Konzultant:	Marcel Vološin

Košice 2022 **Štefan Hadbavný**

Abstrakt v SJ

Hlavným cieľom práce je vytvoriť testovacie prostredie Kubernetes s možnosťou spúšťania úloh strojového učenia. Prvá časť je venovaná terminológii, architektúre platformy Kubernetes a kontajnerizácii. Po analýze nasleduje rozbor hlavných komponentov platformy Kubeflow a definovanie scenárov pre vytvorenie testovacích prostredí zložených z Kubernetes a Kubeflow platforiem. V poslednom rade je zhotovené porovnanie nasadení scenárov, ich výhody a nevýhody. Vypracovaná bola tabuľka pre prehľadný súhrn požiadaviek, výhod a nevýhod implementácií. V prílohe je priložený manuál na vytvorenie testovacieho prostredia využitím Kubernetes a používateľská príručka na implementáciu Python úloh.

Kľúčové slová v SJ

Kubernetes, Kubeflow, Strojové učenie, Kontajnerizácia

Abstrakt v AJ

The main goal of this work is to create a Kubernetes test environment with the possibility running machine learning tasks. The first part is devoted to terminology and architecture of Kubernetes platform and containerization. The analysis is followed by a structure of the main components of the Kubeflow platform and the definition of scenarios for creation test environments composed of Kubernetes and Kubeflow platforms. Last but not least is made a comparison of scenario deployments, their advantages and disadvantages. A table has been prepared for a clear summary of implementations requirements. Attached is a manual for creating a test center using Kubernetes and a user guide for implementing Python tasks.

Kľúčové slová v AJ

Kubernetes, Kubeflow, Machine learning, Containerization

Bibliografická citácia

HADBAVNÝ, Štefan. *Riešenie úloh strojového učenia využitím Kubernetes*. Košice: Technická univerzita v Košiciach, Fakulta elektrotechniky a informatiky, 2022. 38s. Vedúci práce: Marek Ružička

66992

TECHNICKÁ UNIVERZITA V KOŠICIACH

FAKULTA ELEKTROTECHNIKY A INFORMATIKY

Katedra počítačov a informatiky

ZADANIE BAKALÁRSKEJ PRÁCE

Študijný odbor: **Informatika**
Študijný program: **Informatika**

Názov práce:

Riešenie úloh strojového učenia využitím Kubernetes

Solving machine learning tasks using Kubernates

Študent: **Štefan Hadbavný**
Školiteľ: **Ing. Marek Ružička**
Školiace pracovisko: **Katedra počítačov a informatiky**
Konzultant práce: **Ing. Marcel Vološin, PhD.**
Pracovisko konzultanta: **Katedra počítačov a informatiky**

Pokyny na vypracovanie bakalárskej práce:

1. Analyzovať a popísať platformu Kubernetes.
2. Vytvoriť testovacie prostredie využívajúce Kubernetes s možnosťou spúšťania úloh strojového učenia naprogramovaných v jazyku Python.
3. Vytvoriť manuál na pripojenie viacerých počítačov do platformy Kubernetes.
4. Vytvoriť manuál (sériu pokynov s príkladmi) na implementáciu a nasadenie Python zdrojových kódov spustiteľných na platforme Kubernetes.

Jazyk, v ktorom sa práca vypracuje: slovenský
Termín pre odovzdanie práce: 27.05.2022
Dátum zadania bakalárskej práce: 29.10.2021

prof. Ing. Liberios Vokorokos, PhD.
dekan fakulty

Čestné vyhlásenie

Vyhlasujem, že som záverečnú prácu vypracoval samostatne s použitím uvedenej odbornej literatúry.

Košice, 13.5.2022 .....

Vlastnoručný podpis

Poďakovanie

Vyhlasujem úprimné poďakovanie môjmu vedúcemu práce Ing. Marekovi Ružičkovi a konzultantovi Ing. Marcelovi Vološinovi PhD. za odbornú pomoc, cenné rady a čas, ktorý mi venovali pri písaní tejto bakalárskej práce.

Rovnako by som sa rád poďakoval portálu CLOUD TUKE za poskytnutie virtuálnych strojov a pomoci pri konfigurácii.

Obsah

Zoznam obrázkov

Zoznam tabuliek

Úvod

Strojové učenie v dnešnej dobe veľmi rýchlo napreduje. Je dôležitou súčasťou rastúcej oblasti vedy o údajoch. Pomocou štatistických metód sú algoritmy trénované na vytváranie klasifikácií alebo predpovedí, ktoré odhaľujú kľúčové poznatky v rámci rôznych projektov. Tieto poznatky následne riadia rozhodovanie, čo v ideálnom prípade ovplyvňuje kľúčové metriky. Vyžaduje sa od nich, aby pomáhali pri identifikácii najrelevantnejších otázok a následne údajov, ktoré by na nich odpovedali. Pri experimentoch strojového učenia je niekedy vyžadovaný vyšší výkon. Ak sú prístupné viaceré stroje, ktoré sú rozdelené medzi viacerými používateľmi a na danom počítači je žiadaný vyšší výkon, migrovanie údajov manuálne medzi strojmi by bolo zdĺhavé. Ideálnym riešením je, aby Kubernetes bežal na strojoch a nasadzovali by sa naň úlohy bez toho, aby sa muselo riešiť na ktorom stroji sa spustia.

Riešenie úloh strojové učenia sa stáva bežne implementovaným nástrojom na uľahčenie pracovnej záťaže zamestnancov a vedcom v rôznych oblastiach, od kybernetickej bezpečnosti až po služby zákazníkom. Možným riešením, ktoré môže priniesť výhody, je open-source technológia kontajnerizácie Kubernetes. Umožňuje rýchlu, jednoduchú správu a prehľadnú organizáciu kontajnerových služieb a aplikácií. Táto technológia tiež umožňuje automatizáciu prevádzkových úloh, ako je správa dostupnosti aplikácií a škálovanie. Podporuje GPU, čo urýchľuje pracovný tok a automatizuje správu kontajnerov aplikácií akcelerovaných GPU. Tieto nástroje umožňujú využiť rýchlosť GPU v rámci kontajnerového pracovného postupu.

Niekedy sú bežiace postupy na Kubernetes komplikované. Tento problém je možne vyriešiť nadstavbou Kubeflow. Pomáha efektívne spúšťať, organizovať a škálovať modely nezávisle od ich závislostí, ako často musia byť aktívne a koľko údajov potrebujú spracovať. Cieľom Kubeflow je uľahčiť inžinierom strojového učenia a vedcom využívať cloudové prostriedky pre pracovné zaťaženie strojového učenia. Dokáže efektívne vytvorenie modelu pripraveného na produčné použitie za veľmi krátky čas.

Existuje veľa distribútorov, firiem, ktoré vyvíjajú tieto platformy a sú rôzne prispôsobované, preto je cieľom tejto práce otestovať jednotlivé spôsoby a možnosti týchto nasadení. Je potrebné zohľadňovať viaceré faktory. Faktory ako sú podpora grafickej karty, možnosť prepojenia viacerých strojov, systémové požiadavky alebo softverové rámce.

Vyber správnej implementácie je dôležitý. Mala by mať čo najmenej problémov s ktorými sa autor tejto práce stretne a poskytovala čo najlepšie hardvérové využitie.

Formulácia úlohy

Hlavnou úlohou tejto práce je vytvoriť testovacie prostredie Kubernetes s možnosťou spúšťania úloh strojového učenia naprogramovaných v jazyku Python. Najprv je vhodné venovať pozornosť analýze tejto platformy. Platforma Kubernetes je na prvý pohlaď náročná, taktiež vďaka rôznym výrazom, ktoré s ňou súvisia. Na mieste je opis týchto komponentov, architektúry a kontajnerizaciu, pre lepšie pochopenie tejto platformy pre používateľa. Otestovanie nasadení využitím rôznych nástrojov, ktoré je možné otestovať a vyhodnotiť. Uskutočniť prepojenie viacerých počítačov v klastri a odskúšať funkčnosť podpory grafickej karty. Po testovaní je na rade porovnanie a vyhodnotenie jednotlivých scenárov a výber najlepšieho nasadenia vhodného na vyriešenie danej problematiky. V poslednom rade je vyhotovenie manuálu na vytvorenie a pripojenie viacerých počítačov do platformy Kubernetes a manuál (sériu pokynov s príkladmi) na implementáciu a nasadenie Python zdrojových kódov spustiteľných na platforme Kubernetes.

1 Terminológia a technológia Kubernetes

Pri diagrame tried, Greatest Common Divisor (GCD) strojovom učení a experimentoch je niekedy potreba na krátku dobu vyšší výkon. Pravidelné migrovanie medzi strojmi by bolo veľmi zdĺhavé. Tento problém vie veľmi ľahko vyriešiť platforma Kubernetes.

Kubernetes je platforma, ktorá je veľmi robustná v nasadení, správe a orchestrácií kontajnerov. Kontajnery slúžia na zabalenie aplikácie alebo služby a obsahujú všetko potrebné na to, aby fungovali bez ohľadu v akom prostredí a zariadení sa nachádzajú. O kontajneroch je viacej opísané v časti s názvom kontajnerizácia.

Dokáže rozdeliť súčasne záťaž medzi jednotlivými strojmi. Tato platforma v súčasnosti vytlačila predošle platformy a stala sa už štandardom. Automatizuje manuálne procesy, poskytuje mnoho doplnkových služieb, orchestráciu úložiska, vysokú škálovateľnosť, spustiteľnosť, dokáže spravovať viac klastrov súčasne a mnoho iných vlastnosti, ktoré sú spomínané v tejto sekcií [1]. Nasadenie Kubernetes je najefektívnejšie, aj keď existuje dnes veľa podobných technológii a mnoho významných poskytovateľov ponúka klastre Kubernetes.

1.1 Kubernetes

Kubernetes má základnú architektúru klienta a servera. Má schopnosť vykonávať priebežné aktualizácie, prispôsobuje sa aj ďalším pracovným zaťaženiam automatickým škálovaním uzlov, ak je to potrebné, a môže sa tiež opraviť v prípade rozpadu podu. Poskytujú obrovskú výhodu v tom, že aplikácie nebudú mať žiadne výpadky.

Ako orchestrátor sa stará o prácu s plánovaním kontajnerov v klastri a tiež spravuje pracovné zaťaženia. Takmer všetko používa deklaratívne konštrukty, ktoré popisujú, ako sa aplikácie skladajú, ako interagujú a ako sú spravované.

Táto platforma je vhodná na riešenie úloh strojového učenia, aj keď priamo na to je vyvinutý Kubeflow. Je najrýchlejšie rastúcim projektom z Open Source softvéru. Kubernetes je vhodný na riešenie hlavne kvôli výhodám, ktoré sú spomenuté v nasledujúcich podsekciách.

Prenosnosť

Ponúka prenosnosť, rýchlejšie a jednoduchšie nasadenie. To znamená, že v prípade potreby dokáže využívať výhody viacerých cloudov alebo serverov a môžu sa rýchlo rozvíjať bez toho, aby sa musela meniť infraštruktúra.

Škálovateľnosť

Má schopnosť spúšťať kontajnery na jednom alebo viacerých verejných cloudových prostrediach, vo virtuálnych strojoch, čiže je ho možné nasadiť takmer kdekoľvek. Kubernetes zásadne zmenil spôsob vývoja a nasadzovania, je možné škálovať oveľa rýchlejšie, než v minulosti.

Dostupnosť

Rieši vysokú dostupnosť na úrovni aplikácie aj infraštruktúry. Pridanie spoľahlivej úložnej vrstvy do Kubernetes zaisťuje vysokú dostupnosť úloh vykonávaných na jednotlivých inštanciách. Okrem toho môžu byť hlavné komponenty klastra nakonfigurované na multi-node (multi-master), čo tiež zabezpečuje vyššiu dostupnosť.

1.2 Architektúra

Samotnú architektúru Kubernetes tvoria pracovné uzly (worker), hlavný uzol (master) a rozhranie pre programovanie aplikácií oznacované skratkou API. V tejto časti je opísaná architektúra ako tieto uzly fungujú a načo slúži API. Jednotlivé uzly sú zložené z niekoľkých častí, ktoré sú potrebné pre ich správne fungovanie a efektivitu. Pre správne pochopenie ako Kubernetes funguje je treba sa zoznámiť najmä s niektorými termínmi.

1.2.1 Hlavný uzol (master)

V hlavnom uzle nájdeme komponenty, ktoré riadia klaster spolu s údajmi o stave a konfigurácii klastra. Tieto základne komponenty pracujú, aby dokázali zabez-

pečiť, že kontajnery budú fungovať v dostatočnom počte a s potrebnými zdrojmi.

Hlavný uzol je neustále v kontakte s jednotlivými strojmi, ktoré vykonávajú prácu a postará sa o klaster, ako sme ho nakonfigurovali.

Kontajner

Kontajner je podobný virtuálnemu stroju ale kontajner je viac efektívnejší, podobne ako virtuálny stroj ma vlastný súborový systém, zdieľaný procesor, operačnú pamäť a ďalšie. Sú funkčne na rôznych operačných systémoch, pretože sa oddeľujú od základnej infraštruktúry [2]. Výrazne zvyšujú efektivitu, vyžadujú menej systémových prostriedkov, pretože neobsahujú obraz operačného systému. Zabezpečujú lepší vývoj aplikácii a lepšiu prenosnosť. Podrobnejšie informácie sa nachádzaju v časti s názvom kontajnerizácia.

Mikroslužby

V mikroslužbách sa jedna aplikácia skladá z mnohých voľne prepojených nezávisle nasaditeľných menších komponentov alebo služieb. Najdôležitejšou charakteristikou mikroslužieb je to, že sú služby menšie a samostatne nasaditeľné. Nevyžaduje, aby sa menil riadok kódu alebo pridala nová funkcia do aplikácie. Vytvára určitý stupeň izolácie porúch, lepšiu odolnosť aplikácií a malá veľkosť služieb uľahčuje porozumieť základy kódu. V modeli mikroslužieb sú komponenty nasadené nezávisle a komunikujú cez určitú kombináciu REST, streamovania udalostí a sprostredkovateľov správ. Na základe toho je možné, aby bol zásobník každej jednotlivej služby optimalizovaný pre túto službu. Technológia sa neustále mení a aplikácia zložená z viacerých menších služieb je oveľa jednoduchšia a menej nákladná na vývoj pomocou vhodnejšej technológie, keď bude dostupná [3]. Nie je vhodné vytvárať príliš veľa mikroslužieb, kvôli tomu, že môže dôjsť do väčších zložitosti. Je lepšie prikloniť sa k väčším službám a potom ich postupne rozdeľovať, keď začnú vykazovať kroky, ktoré mikroslužby majú riešiť. Následne sa dátový model stáva príliš zložitým. Často sa používajú pri cloudových službách a aplikácii, ktoré sa nasadzujú pomocou kontajnerov.

Uzol

Uzol môže byt virtuálny stroj alebo fyzicky počítač, kde sú nasadené kontajnery. Za prijímanie a spúšťanie pracovných zaťažení a externých zdrojov sú zodpovedné uzly. Kubernetes spúšťa aplikácie a služby v kontajneroch na pomoc s izoláciou, správou a flexibilitou. Každý uzol musí mať modul tzv. behové prostredie

kontajnera. Uzol prijíma pracovné pokyny od hlavného uzla a podľa toho vytvára alebo ruší kontajnery a zároveň prispôsobuje pravidla sieťovej prevádzky.

Pod

Pod je skupina jedného alebo viacerých kontajnerov so zdieľaným úložiskom, sieťou a špecifikáciou ako majú kontajnery fungovať. Môžeme mať dva typy spustenia a to je cloudové a necloudové. Pri necloudových, takzvanom lokálnom prostredí, sú spúšťané na rovnakom fyzickom alebo virtuálnom stroji a pri cloudových napríklad zdieľaných, vzdialených cloudoch na rovnakom logickom hostiteľovi. Všetky kontajnery v pode môžu medzi sebou komunikovať a aj sú na samostatných uzloch. Sú vytvorené na základe pracovného zaťaženia nazývanými ovládače, ktoré riadia vytváranie, kopírovanie a stav podov v klastri. Ak napríklad zlyhá uzol v klastri, ovládač zisti, že moduly v tomto uzle nereagujú a vytvorí náhradne moduly na iných uzloch.

Klaster

V klastroch sa spúšťajú kontajnerové aplikácie, ktoré spravuje Kubernetes. Klaster je v podstate séria uzlov spojených dohromady. Spojením uzlov zhromažďujú svoje zdroje (CPU, RAM, atď.). Klaster je v tom prípade oveľa výkonnejší ako jednotlivé stroje. Kubernetes presúva pody po klastri, pri pridávaní alebo odstraňovaní uzlov [4]. Sú to navzájom prepojené počítače, ktoré vykonávajú určitú činnosť.

Kube-apiserver

Tento komponent odhaľuje API hlavnému uzlu. V podstate funguje ako frontend k informáciám o stave klastra a premosťuje API s inými objektmi Kubernetes, napríklad modulmi, radičmi a službami. Server API určuje, ci je požiadavka platná, a ak áno, spracuje ju. K API sa pristupuje prostredníctvom Rest, cez rozhranie príkazového riadka kubectl alebo prostredníctvom iných nástrojov napríklad kubeadm. Zabezpečuje všetku interakciu medzi komponentmi [5].

Kube-controller-manager

Na hlavnom uzle riadi všetky ovládače. Každý ovládač je vlastne samostatný individuálny proces. Pre zjednodušenie správy klastrov sú však všetky skompilované do jedného procesu, Za túto kompiláciu je zodpovedný kube-controller-manager.

Jeden ovládač konzultuje s plánovačom a uisťuje sa, že beží správny počet podov. Ak pod spadne, iný ovládač si to všimne a zareaguje. Ovládač pripája služby k podom, takže požiadavky smerujú do správneho koncového bodu. Existujú aj ovládače na vytváranie účtov a prístupových tokenov API [6].

Etcd

Názov je zložený z dvoch myšlienok. Z unix (/etc) priečinka a (d) ako distributed systems v preklade distribuovaných systémov. Ukladá informácie o konfigurácii pre veľké distribuované systémy. Kubernetes teda používa etcd ako úložisko hodnôt jednotlivých kľúčov. Etcd modul musí byt stále dostupný, aby sa zabezpečilo správne fungovanie služieb [7]. Údaje Etcd sú veľmi dôležíté a odporúča sa vytvoriť si zálohu.

Plánovač

Z názvu môžeme posúdiť, že slúži na plánovanie rozhodnutí pre novovytvorené pody. Keď je pod vytvorený, musí mu byť priradený uzol, na ktorom sa má spustiť. Plánovač prijíma informácie z API o požiadavkách a špecifikáciách podov a IT zdrojoch na dostupných uzloch. Potom priradí každý pod k príslušnému uzlu. Ak plánovač nemôže nájsť vhodný uzol, pod zostane nenaplánovaný a plánovač zopakuje proces, kým nebude dostupný uzol.

1.2.2 Pracovný uzol (worker)

V pracovnom uzle, komponent, ktorý sa nasadzuje ako prvý je behové prstredie kontajnera. Zvyčajne sa inštaluje spustením Dockera, ale dostupné sú aj alternatívy ako rkt a runc. Beh programu kontajnera je zodpovedný za spustenie a správu kontajnerov, aplikácií zapuzdrených v relatívne izolovanom, ale ľahkom ako keby operačnom prostredí.

Každá jednotka práce v klastri je na svojej základnej úrovni implementovaná ako jeden alebo viac kontajnerov, ktoré je potrebné nasadiť.

Kubelet

Kubelet je agent, ktorý je spustený na každom pracovnom uzle v klastri. Je to dôležitý komponent, pretože prijíma inštrukcie z hlavného uzla. Kubelet v podstate riadi pody. Zabezpečuje, že všetky kontajnery bežia v pode a že tieto pody sú v poriadku a bežia v správnych časových intervaloch. Číže vytvára a odstraňuje

moduly, na základe pokynov od hlavného uzla, ktoré moduly je potrebné pridať alebo odstrániť. Keď riadiaci uzol potrebuje, aby sa niečo vykonalo v uzle, kubelet vykoná tuto akciu.

Kube-proxy

Na správu jednotlivých hostiteľských podsietí a sprístupnenie služieb iným komponentom je na každom uzlovom serveri spustená malá proxy služba s názvom kube-proxy . Tento proces preposiela požiadavky správnym kontajnerom, môže vykonávať primitívne vyvažovanie záťaže a je vo všeobecnosti zodpovedný za zabezpečenie toho, aby bolo sieťové prostredie predvídateľné a dostupné, ale v prípade potreby izolované [8]. Používa proxy UDP, TCP a SCTP, ale nerozumie HTTP.

1.2.3 API

API je front end (používateľské rozhranie) a je spôsob, akým používatelia interagujú s klastrom Kubernetes. Určuje, či je požiadavka platná a potom ju spracuje. V podstate API je rozhranie používané na správu, vytváranie a konfiguráciu klastrov. Každá akcia vykonaná v klastri prechádza cez API. Takto spolu komunikujú používatelia, externé komponenty a ostatné časti klastra. V strede riadiacej roviny (master) je server API a HTTP API, ktoré umožňujú komunikovať a manipulovať so stavom objektov Kubernetes.

Komunikácia s API serverom prebieha cez rôznych klientov a to napríklad cez Ul (dashboard), použitím Kubernetes API alebo príkazovým riadkom nazývaným kubectl. V tejto časti sa nachádzajú informácie o jednotlivých klientoch.

kubectl

Po vytvorení klastra Kubernetes je potrebné interagovať s týmto klastrom. Prvým krokom je vytvorenie podov v klastri a ostatných komponentov a na tieto interakcie slúži kubectl. Je najmocnejší, oficiálny nástroj rozhrania príkazového riadka Kubernetes na prácu s klastrom. S týmto príkazovým riadok je možné robiť mnoho veci. Ak kubectl odošle príkaz ako vytvoriť komponent, odstrániť komponent atď. API serveru, následne pracovné uzly zareagujú a vykonajú tieto príkazy. Je možne komunikovať s rôznym typom klastrom, či už je to lokálny, cloudový alebo hybridný klaster.

1.3 Nástroje na vytváranie klástrov

Nástroje slúžia na vytváranie lokálneho klastra a následne pracovanie s týmto klastrom. V tejto časti sú porovnané nástroje aké majú odlišnosti a čo ponúkajú.

minikube

Ide o spôsob vytvárania virtuálneho počítača, ktorý je v podstate klastrom Kubernetes s jedným uzlom. Vďaka podpore množstva hypervízorov ho možno použiť na všetkých hlavných operačných systémoch. To tiež umožňuje vytvárať viacero inštancií paralelne.

Z užívateľského hľadiska je minikube veľmi priateľský nástroj pre začiatočníkov. Klaster sa spúšťa pomocou minikube start, následne kubectl je pripravený na použitie. Na určenie verzie sa používa príkaz –kubernetes-version.

Pre nových používateľov môže výrazne pomôcť dashboard, ktorý minikube ponúka. Dashboard sa jednoducho otvorí a poskytuje pekný prehľad o všetkom, čo sa deje v klastri. Minikube taktiež umožňuje pridávať rôzne rozšírenia, ktoré pomáhajú integrovať napríklad dashboard, grafické karty od Nvidie a oveľa viac. Pomocou minikube sa vykonávajú príkazy ako vytvoriť, aktualizovať, odstrániť klaster lokálne na počítači. Je užitočný, pre rýchle vytvorenie malého testovacieho klastra. Používa celkom jednoduché príkazy na vytváranie a odstráňovanie.

kind

Presúva klaster do kontajnerov Docker. To vedie k výrazne vyššej rýchlosti spustenia v porovnaní s vytváraním virtualizácie.

Vytvorenie klastra je veľmi podobné ako pri minikube. Použitím príkazu kind create cluster, vytvárame klaster. Použitím rôznych názvov –name, kind umožňuje vytvárať viaceré inštancie paralelne.

Významnou funkciou, je možnosť načítať obrazy kontajnerov priamo do klastra. To ušetrí niekoľko ďalších krokov pri nastavovaní registra a načítavaní obrazu, keď treba vyskúšať nejaké zmeny. S jednoduchým kind load docker-image my-app:latest je kontajnerový obraz k dispozícii na použitie v klastri.

k3s

K3s je verzia Kubernetes vyvinutá spoločnosťou Rancher Labs. Odstránením postradateľných funkcií (legacy, in-tree pluginy) a použitím ľahkých komponentov

(napr. sqlite3 namiesto etcd3) dosiahli výrazné zmenšenie. Výsledkom je jeden binárny súbor s veľkosťou približne 60 MB.

Aplikácia je rozdelená na server K3s a agenta. Prvý pôsobí ako manažér, zatiaľ čo druhý zodpovedá za zvládnutie skutočného pracovného zaťaženia. Pri spúšťaní na počítací môže dôjsť k výraznému neporiadku v lokálnom súborovom systéme. Namiesto toho sa vkladá k3s do kontajnera (napr. pomocou rancher/k3s), ktorý tiež umožňuje ľahko spustiť niekoľko nezávislých inštancií.

Jedna funkcia, ktorá vyniká, sa nazýva automatické nasadenie. Umožňuje nasadiť manifesty Kubernetes a grafy Helm ich umiestnením do konkrétneho adresára. Špecifikácie objektu Kubernetes API vo formáte JSON alebo YAML nazývame manifesty Kubernetes. Spolu s grafmi Helm sú manifesty Kubernetes YAML spojené do jedného balíka. K3s sleduje zmeny a stará sa o ich aplikáciu bez akejkoľvek ďalšej interakcie. Je to užitočné najmä pre CI pipelines a zariadenia IoT. CI pipelines sa vyznačujú sériou etáp a automatizovaných krokov, ktorými softvér prechádza a IoT značí moderné zariadenia, ktoré sú ovládateľné aj na diaľku cez internet. Stačí vytvoriť/aktualizovať konfiguráciu a K3s sa postará o to, aby boli nasadenia (deployments) aktuálne [9].

MicroK8s

Sťahuje sa ako inštalačný balík, ktorý nainštaluje jednouzlový (samostatný) klaster K8s za menej ako 60 sekúnd. Da sa použiť aj na vytvorenie klastra s viacerými uzlami pomocou niekoľkých príkazov. MicroK8s má všetky základné komponenty Kubernetes, ako napríklad DNS a Dashboard, sú dostupné použitím jediného príkazu. Je k dispozícii pre väčšinu populárnych distribúcií Linuxu a tiež pre pracovné stanice Windows a Mac prostredníctvom natívneho inštalátora pre oba operačné systémy. V systéme Windows je tiež možnosť získať MicroK8s na WSL [10].

Každý z týchto nástrojov poskytuje ľahko použiteľné prostredie Kubernetes pre viacero platforiem, no odlišujú ich niekoľko faktorov. K3s napríklad ponúka prostredie Kubernetes založené na virtualizácii. Pre nastavenie viacero serverov Kubernetes, je potreba manuálne nakonfigurovať ďalšie virtuálne stroje alebo uzly, čo môže byť dosť náročné. Je však navrhnutý na použitie pri nasadzovaní, čo z neho robí jednu z najlepších možností na lokálne simulovanie skutočného nasadzovacieho prostredia. Aj keď je minikube vo všeobecnosti skvelou voľbou pre lokálne spúšťanie Kubernetes, jednou z hlavných nevýhod je, že môže spustiť iba jeden uzol v miestnom klastri, čo zas vyúsťuje k tomu, že je o niečo ďalej

k produkčnému multiuzlovému prostrediu. Na rozdiel od miniKube môže microK8S prevádzkovať viacero uzlov v lokálnom klastri. Inštalácia microK8S na počítače so systémom Linux, ktoré nepodporujú balík snap, je náročná v porovnaní s inými nástrojmi v tomto zozname. microK8S používa balík snap vytvorený spoločnosťou Canonical na inštaláciu strojového nástroja Linux, čo sťažuje spustenie na distribúciách Linuxu, ktoré ho nepodporujú. MiniKube sa tiež inštaluje na viacero platforiem pomocou virtualizácie.

1.4 Kontajnerizácia

Kontajnery predstavujú metódu virtualizácie operačného systému, ktorá umožňuje spúšťať aplikáciu a jej závislosti v procesoch izolovaných na zdrojoch. Kontajnery umožňujú jednoducho zbaliť kód aplikácie, konfigurácie do ľahko použiteľných stavebných blokov, ktoré poskytujú environmentálnu konzistentnosť, prevádzkovú efektivitu, produktivitu vývojárov a kontrolu verzií. Kontajnery môžu pomôcť zabezpečiť rýchle, spoľahlivé a konzistentné nasadenie aplikácií bez ohľadu na prostredie nasadenia. Kontajnery tiež poskytujú podrobnejšiu kontrolu nad zdrojmi, čo zvyšuje efektivitu infraštruktúry. V minulosti sa aplikácie spúšťali na fyzických serveroch. Neexistovala možnosť ako nastaviť obmedzenia pre aplikácie na serveroch a to spôsobovalo problémy. Napríklad, ak viaceré aplikácie bežali na jednom serveri, tak existovali tam inštancie, ktoré využívali väčšinu výkonu servera a ďalšie, ktoré nemali dostatočný výkon na vykonávanie akcii. To sa už v dnešných časoch veľmi nevyužíva, tato metóda bola príliš nákladná na údržbu mnohých fyzických serverov [11].

Nasadzovanie aplikácie na virtualizovaných serveroch bolo predstavené ako riešenie. Umožňuje spustiť viacero virtuálnych strojov na jeden fyzicky server. Virtualizácia umožňuje izolovať aplikácie od seba a zabezpečiť, že k informáciám jednej aplikácie sa nedostane druha aplikácia. Virtualizácia umožňuje lepšie využitie výkonu na serveri, aplikáciu umožňuje pridať, aktualizovať a taktiež znížene náklady na hardvér.

Kontajnery sú podobné virtuálnym počítačom, ale majú uvoľnené izolačné vlastnosti na zdieľanie operačného systému medzi aplikáciami. Preto sa kontajnery považujú za jednoduchšie. Podobne ako virtualizácia, kontajner má svoj vlastný súborový systém, zdieľané CPU, pamäte, procesného priestoru a ďalšie. Keďže sú oddelené od základnej infraštruktúry, sú prenosné cez cloudy a distribúcie operačných systémov.

Stali sa obľúbenými, pretože poskytujú veľa výhod:

- Vyššia rýchlosť dodávania vylepšení. Kontajnerovanie monolitických aplikácií pomocou mikroslužieb pomáha vývojovým tímom vytvárať funkcie s vlastným životným cyklom a zásadami škálovania.
- Vylepšená bezpečnosť izoláciou aplikácií od hostiteľského systému a od seba navzájom.
- Nepretržitý vývoj, integrácia a nasadzovanie. Poskytuje spoľahlivé a časté vytváranie a nasadzovanie obrazu kontajnera.
- Prenosnosť cloudu a distribúcie operačných systémov, na veľkých verejných cloudoch a kdekoľvek inde.
- Menšia záťaž. Kontajnery vyžadujú menej systémových prostriedkov ako tradičné alebo hardvérové prostredia virtuálnych strojov, pretože nezahŕňajú operačne systémy.

1.4.1 Kontajnerový obraz, beh programu a orchestrácia

Súbory kontajnerového obrazu sú statické a spustiteľné verzie aplikácie alebo služby a líšia sa od jednej technológie k druhej. Obraz sa skladá z viacerých vrstiev, ktoré začínajú základným obrazom, ktorý obsahuje všetky závislosti potrebné na spustenie kódu v kontajneri. Každý obraz má na vrchu statických nemenných vrstiev čitateľnú a zapisovateľnú vrstvu. Pretože každý kontajner má svoju vlastnú špecifickú vrstvu kontajnera, ktorá prispôsobuje tento konkrétny kontajner, podkladové vrstvy obrazu možno uložiť a znova použiť vo viacerých kontajneroch. Pre otvorený kontajner sa obraz skladá z manifestu, vrstiev súborového systému a konfigurácií. Pre správne fungovanie kontajnera, musí mať behové prstredie a špecifikáciu obrazu. Špecifikácie behu programu predstavujú fungovanie súborového systému, čo sú súbory obsahujúce všetky potrebné údaje pre chod. Špecifikácia obrazu obsahuje informácie potrebné na spustenie aplikácie alebo služby v kontajneri [12].

Kontajnerový systém spúšťa obrazy a väčšinou sa používajú na správu nasadení kontajnerov alebo technológiu orchestrácie, ako je Kubernetes. Kontajnery majú vysokú prenosnosť, pretože každý obraz obsahuje závislosti potrebné na spustenie kódu v kontajneri. Používatelia kontajnera môžu napríklad počas testu spustiť rovnaký obraz na rôznej cloudovej platformy bez zmeny kódu aplikácie v kontajneri.

Orchestrácia kontajnerov umožňuje vývojárom nasadiť veľké množstvo kontajnerov a spravovať ich vo veľkom meradle pomocou konceptu klastrov kontajne-

rov. Orchestrátor pomáha správcom IT automatizovať proces spúšťania inštancií kontajnerov, poskytovania hostiteľov a spájania kontajnerov do funkčných skupín. S kontajnerovou orchestráciou je možné riadiť životný cyklus aplikácií, pozostávajúci z veľkého počtu kontajnerov.

Orchestrácia ma tieto privilégiá:

- Automaticky nasadzuje kontajnery na základe politík, zaťaženia aplikácií a metrík prostredia.
- Identifikujte neúspešné kontajnery alebo zhluky a opravuje ich.
- Spravuje konfiguráciu aplikácie.
- Pripája kontajnery k úložisku a spravuje sieť.
- Zlepšuje bezpečnosť obmedzením prístupu medzi kontajnermi a externými systémami.

Príklady orchestrátorov sú napríklad Kubernetes, OpenShift, Docker atď.

1.4.2 Architektúra mikroslužieb

Architektúra mikroslužieb rozdeľuje aplikáciu na viacero nezávislých služieb. Každý z nich má svoj vlastný kanál a môže byť nasadený do produkcie kedykoľvek, bez závislosti od iných mikroslužieb.

Bežný spôsob vytvárania a nasadenia mikroslužieb je v kontajneroch. Celá aplikácia mikroslužieb môže byť nasadená ako klaster pomocou kontajnerového orchestrátora. Existuje niekoľko výhod používania kontajnerov pre mikroslužby, na rozdiel od úplných virtuálnych strojov alebo fyzických počítačových serverov: [13]

- Sú jednoduché, čo umožňuje spúšťať viac inštancií mikroslužieb na jednom fyzickom hostiteľovi.
- Kontajnery sa dajú ľahko automatizovať a úzko sa integrovať s pracovnými postupmi.
- Kontajnery sú nemenné, vďaka čomu je ľahké vymazať a nahradiť inštancie mikroslužieb pri vydaní nových verzií.
- Kontajnery sú ľahko prenosné medzi miestnymi vývojovými prostrediami, lokálnymi dátovými centrami a cloudovými prostrediami, čo umožňuje vyvinúť mikroslužby v jednom prostredí a nasadiť ich do iného.

1.4.3 Virtualizácia a kontajner

V dobe, kedy výkony a parametre serverov boli na menšej úrovni a postupne sa zvyšovali, zrodili sa virtuálne stroje, navrhnuté spustením softvéru nad fyzickými servermi na emuláciu konkrétneho hardvérového systému. Hypervizor je softvér, firmvér alebo hardvér, ktorý vytvára a spúšťa virtuálne počítače. Je to to, čo sa nachádza medzi hardvérom a virtuálnym strojom a je potrebný na virtualizáciu servera. V rámci každého virtuálneho počítača beží jedinečný hosťujúci operačný systém. Virtuálne počítače s rôznymi operačnými systémami môžu bežať na rovnakom fyzickom serveri. Virtuálny stroj so systémom UNIX môže byť vedľa virtuálneho počítača so systémom Linux atď. Každý stroj má svoje vlastné binárne súbory, knižnice a aplikácie, ktoré obsluhuje, a môže mať veľkosť mnoho gigabajtov [14].

Vývoj tiež profitoval z tejto fyzickej konsolidácie, pretože väčšie využitie na väčších a rýchlejších serveroch uvoľnilo následne nepoužívané servery na opätovné použitie na kontrolu kvality, vývoj alebo laboratórne vybavenie. Ale tento prístup mal aj svoje nevýhody. Každý virtuálny stroj obsahuje samostatný obraz operačného systému, ktorý zvyšuje nároky na pamäť a úložný priestor. Ako sa ukázalo, tento problém pridáva na zložitosti všetkým fázam životného cyklu vývoja softvéru, od vývoja až po testovanie na výrobu a obnovu po havárii. Tento prístup tiež výrazne obmedzuje prenosnosť aplikácií medzi verejnými cloudmi, súkromnými cloudmi a tradičnými dátovými centrami. Virtualizácia operačných systémov v poslednom desaťročí narástla na popularite, aby umožnila softvéru predvídateľne a dobre fungovať pri presune z jedného serverového prostredia do druhého. Kontajnery však poskytujú spôsob, ako spustiť tieto izolované systémy na jednom serveri [15].

Na obrázku je graficky znázornené ako kontajnery sú umiestnené na vrchole fyzického servera a jeho hostiteľského operačného systému napríklad Linux alebo Windows. Každý kontajner zdieľa jadro hostiteľského operačného systému a zvyčajne aj binárne súbory a knižnice. Zdieľané komponenty sú len na čítanie. Kontajnery sú teda výnimočne v tom, že majú veľkosť iba niekoľko megabajtov a ich spustenie trvá len niekoľko sekúnd, na rozdiel od gigabajtov a minút pre virtualizáciu.

Kontajnery tiež znižujú riadenie, pretože zdieľajú spoločný operačný systém, iba jeden operačný systém potrebuje starostlivosť a zásobovanie pre opravy chýb, záplaty atď. Stručne povedané, kontajnery sú jednoduchšie a prenosnejšie ako virtuálne počítače.

Virtuálne stroje a kontajnery sa líšia niekoľkými spôsobmi, ale hlavný rozdiel

je v tom, že kontajnery poskytujú spôsob virtualizácie operačného systému, takže na jednej inštancii operačného systému môže bežať viacero pracovných zaťažení. V prípade virtuálnych počítačov sa hardvér virtualizuje, aby bolo možné spustiť viacero inštancií operačného systému. Rýchlosť, svižnosť a prenosnosť kontajnerov z nich robí ďalší nástroj, ktorý pomáha zefektívniť vývoj softvéru. Porovnanie je zdôraznené aj na obrázku nižšie pre lepší prehľad.

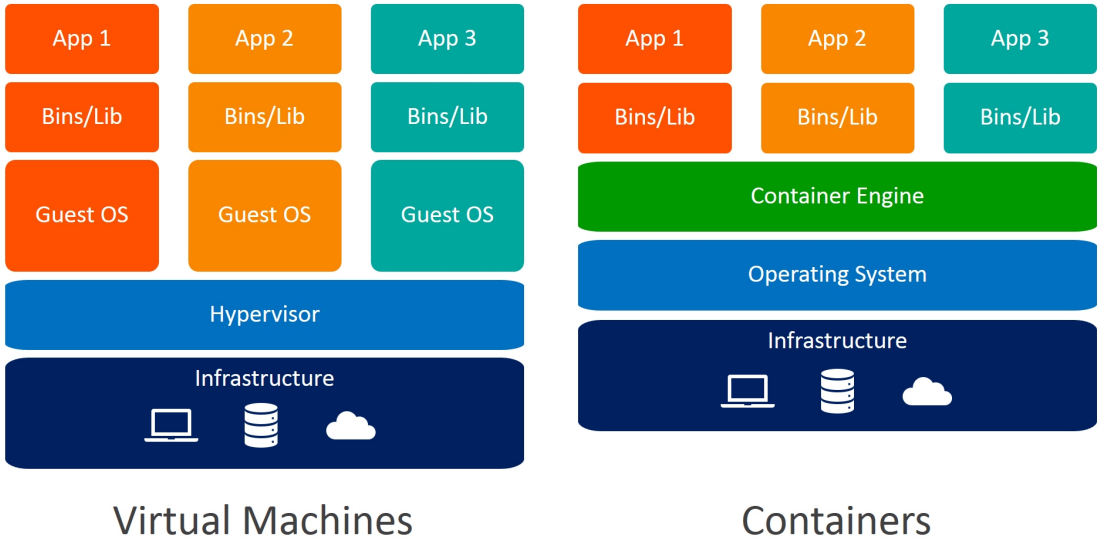

Obr. 1.1: Porovnanie infraštruktúry kontajnera a virtualizácie [16]

1.4.4 Systemový a aplikačný kontajner

Aplikačné kontajnery, ako napríklad Docker, zapuzdrujú súbory a knižnice aplikácie, ktoré sa majú spustiť na operačnom systéme. Aplikačné kontajnery umožňujú používateľovi vytvoriť a spustiť samostatný kontajner pre viacero nezávislých aplikácií alebo viacero služieb, ktoré tvoria jednu aplikáciu. Napríklad aplikačný kontajner by bol vhodný pre aplikáciu mikroslužieb, kde každá služba, ktorá tvorí aplikáciu, beží nezávisle jedna od druhej [17].

Systémové kontajnery, sú technologicky podobné kontajnerom aplikácií aj virtuálnym strojom. Systémový kontajner môže spúšťať operačný systém, podobne ako by operačný systém bežal zapuzdrený na virtuálnom stroji. Systémové kontajnery však neemulujú hardvér systému, namiesto toho fungujú podobne ako aplikačné kontajnery a používateľ si môže nainštalovať rôzne knižnice, jazyky a systémové databázy [18].

Takže všeobecne, keď je potrebné distribuovať aplikáciu ako komponenty, aplikačné kontajnery sú skvelá voľba. Ak je iba operačný systém, do ktorého je treba

nainštalovať rôzne knižnice, jazyky, databázy atď. vhodnejšie sú systémové kontajnery.

2 Využitie technologií v praxi

Na vyriešenie problematiky nasadenia strojového učenia na platforme Kubernetes sú v tejto časti poskytnuté postupy na lokálne nasadenie na zariadeniach ako je laptop alebo stolný počítač. Jedna sa prevažne o platformu Kubeflow. Riešenia, ktoré sú poskytnuté sú mierne hardverovo záťažové, čo znamená, že sú vhodné pre zariadenia s hardvérovým vybavením minimálne 4 GB veľkou operačnou pamäťou a s voľným priestorom na disku. Dodané postupy sú vhodné, či už pre slabšie zariadenia ale aj výkonovo silnejšie pre plné nasadenie platformy.

2.1 Kubeflow

Kubeflow ako platforma, je vhodná na nasadenie a vývoj strojového učenia. Primárne slúži pre inžinierov a vedcov, ktorý pracujú s dátami. Obsahuje viaceré komponenty, z ktorých si vývojári môžu vybrať, čo je pre ich používateľov najlepšie, čo znamená, že na nasadzovanie nie je potrebný každý jeden komponent.

2.1.1 Komponenty

Stavia na platforme Kubernetes ako systéme na nasadenie, škálovanie a správu zložitých systémov. Pomocou konfiguračných rozhraní Kubeflow, môžeme špecifikovať nástroje strojového učenia, potrebné pre náš pracovný postup. Potom môžeme nasadiť pracovný postup do rôznych cloudov, miestnych platforiem na experimentovanie a na produkčné použitie.

V tejto časti sú priblížené všetky šesť komponenty, ktoré tvoria Kubeflow.

Pipelines

Pipelines sa používajú na vytváranie a nasadzovanie prenosných, škálovateľných, pracovných postupov strojového učenia založených na kontajneroch Docker. Pozostávajú z používateľského rozhrania na správu tréningových experimentov, úloh a chodov a z nástroja na plánovanie viackrokových pracovných postupov strojo-

vého učenia. Existujú aj dve súpravy SDK, jedna umožňuje definovať a manipulovať s pipelines, zatiaľ čo druhá ponúka alternatívny spôsob interakcie Notebookov so systémom [19].

Notebooks

Jupyter notebooks fungujú s Kubeflow veľmi dobre, pretože sa dajú ľahko integrovať s typickými mechanizmami overovania a kontroly prístupu. Používatelia môžu bezpečne a s istotou vytvárať notebookové moduly/servery priamo v klastri Kubeflow pomocou obrazov poskytnutých správcami a jednoducho odosielať úlohy s jedným uzlom v porovnaní s tým, že si musia všetko nakonfigurovať na svojom laptope.

Katib

Katib je škálovateľný a rozšíriteľný framework, ktorý podporuje ladenie hyperparametrov a vyhľadávanie neurónovej architektúry. Umožňuje používateľom objaviť modely, ktoré sú rovnako dobré ako ručne vytvorené modely, bez toho, aby museli prejsť namáhavým manuálnym procesom konfigurácie a opakovania. Katib organizuje optimalizáciu alebo vyhľadávanie neurónovej architektúry a presúva ju do sekcie s názvom Experiment. Algoritmy bežia interaktívnym spôsobom. Experiment definuje vyhľadávací priestor, cieľ metrík a maximálny počet iterácií. Katib hľadá iteratívne vo vyhľadávacom priestore, aby splnil cieľ metrík alebo aby dosiahol maximálny počet opakovaní. Katib podporuje dva rôzne mechanizmy – Hyperparameter Tuning a Neural Architecture Search [20].

Ladenie hyperparametrov je proces optimalizácie hodnôt hyperparametrov modelu s cieľom maximalizovať predikčnú kvalitu modelu. Príkladmi takýchto hyperparametrov sú rýchlosť učenia, hĺbka neurálnej architektúry (vrstvy) a šírka (uzly), epochy, veľkosť dávky, miera výpadkov a aktivačné funkcie. Toto sú parametre, ktoré sa nastavujú pred tréningom; na rozdiel od parametrov modelu (váhy a odchýlky) sa tieto nemenia počas procesu trénovania modelu.

Training operators

Operátor Kubeflow pomáha nasadzovať, monitorovať a spravovať životný cyklus Kubeflow. Je zložený z Operator frameworku, čo je súprava nástrojov s otvoreným zdrojovým kódom na zostavovanie, testovanie, balenie operátorov a správu životného cyklu operátorov. Operátor Kubeflow používa KfDef ako svoj vlastný zdroj a kfctl ako základný nástroj na spustenie operátora.

Napríklad operátor k8s spadá pod Kubeflow. Tento operátor uľahčuje spúšťanie úloh tensorflow, či už sú distribuované alebo nedistribuované na kubernetes. TFjobs sú vlastným zdrojom Kubernetes, ktorý sa používa na trénovanie alebo spustenie úloh trénovania na Kubernetes. Kubeflow udržiava všetky tieto operátory a dá sa povedať, že Kubeflow zhromažďuje také komponenty, ktoré uľahčujú spustenie kódu strojového učenia v rôznych formách v rámci Kubernetes. Takže potrebný je operátor pre TFJob, ktorý to bude monitorovať a sledovať. Nasadenie Kubeflow, dokáže rozšíriť nasadenia operátorov, a potom podľa toho definovať TFjobs a spustiť toľko, koľko tréningov je potrebné na klastri kubernetes [21].

Multi-Tenancy

Po nainštalovaní a nakonfigurovaní Kubeflow sa predvolene pristupuje k primárnemu profilu. Profil vlastní menný priestor Kubernetes s rovnakým názvom spolu s kolekciou zdrojov Kubernetes. Používatelia majú prístup na zobrazenie a úpravu svojich primárnych profilov. Prístup k profilu je možné zdieľať s iným používateľom v systéme. Pri zdieľaní prístupu k profilu je na výber, aký prístup je možné poskytnúť na čítanie alebo prístup na čítanie/úpravu. Na všetky praktické účely pri práci s centrálnym ovládacím panelom Kubeflow je aktívny menný priestor priamo prepojený s aktívnym profilom.

Rozhranie

Centrum riadenia komponentov, ktoré poskytuje používateľovi prístup k jednotlivým komponentom v klastri ako sú Pipelines, Notebooks, Katib, Artifact store a Multi-Tenancy.

Na nasledujúcom obrázku je možné vidieť rozhranie a niektoré komponenty, ktoré kubeflow ponúka.

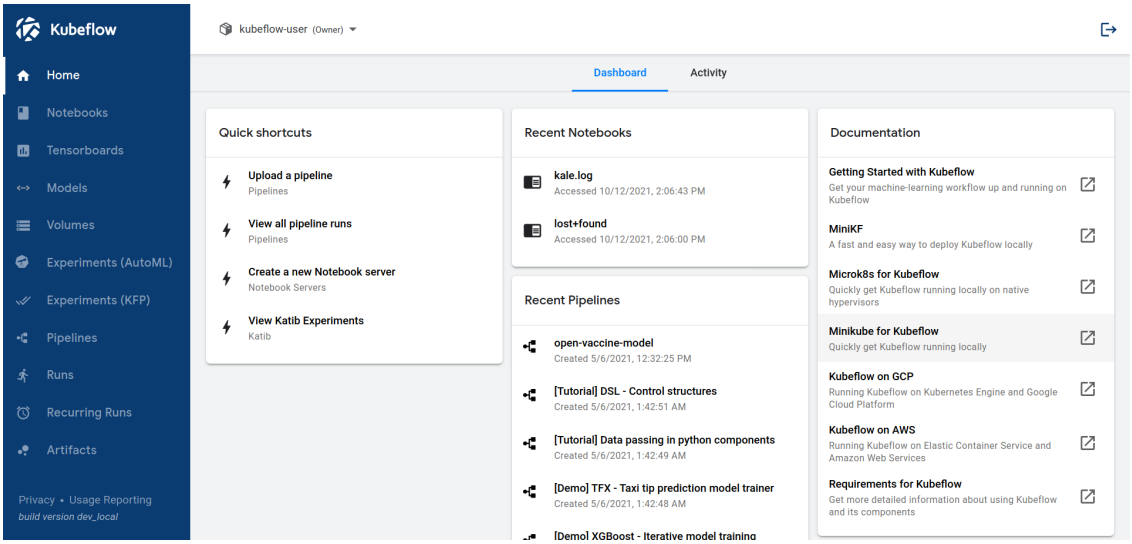

Obr. 2.1: Rozhranie Kubeflow

2.1.2 Pracovný postup

Postup pozostáva z viacerých krokov, taktiež z iterácie, ktorá je hlavným prvkom pri vyvíjaní sýtemu strojového učenia. Pri tomto postupe je potrebné vykonávať zmeny v parametroch aby sme dosiahli požadované výsledky. Následne si povieme niečo viac o týchto postupoch.

Ako prvé by sme mali vyvíjať model na základe predpokladov a testov. Môžeme ho opísať v nasledujúcich bodoch: [22]

- Identifikovanie problému, ktorý ma systém vyriešiť.
- Zbieranie dát, ktoré potrebujeme na trénovanie modelu.
- Vyberanie algoritmu a nakódovanie modelu.
- Experiment s údajmi a trénovanie modelu.
- Vyladenie parametrov.

Ďalej môžeme nasadiť systém, ktorý bude vykonávať tieto procesy:

- Transformáciu údajov, ktoré náš systém potrebuje.
- Trénovanie modelu.
- Podanie modelu na online prevádzku.
- Monitorovanie výsledkov na úpravu a zmenu modelu.

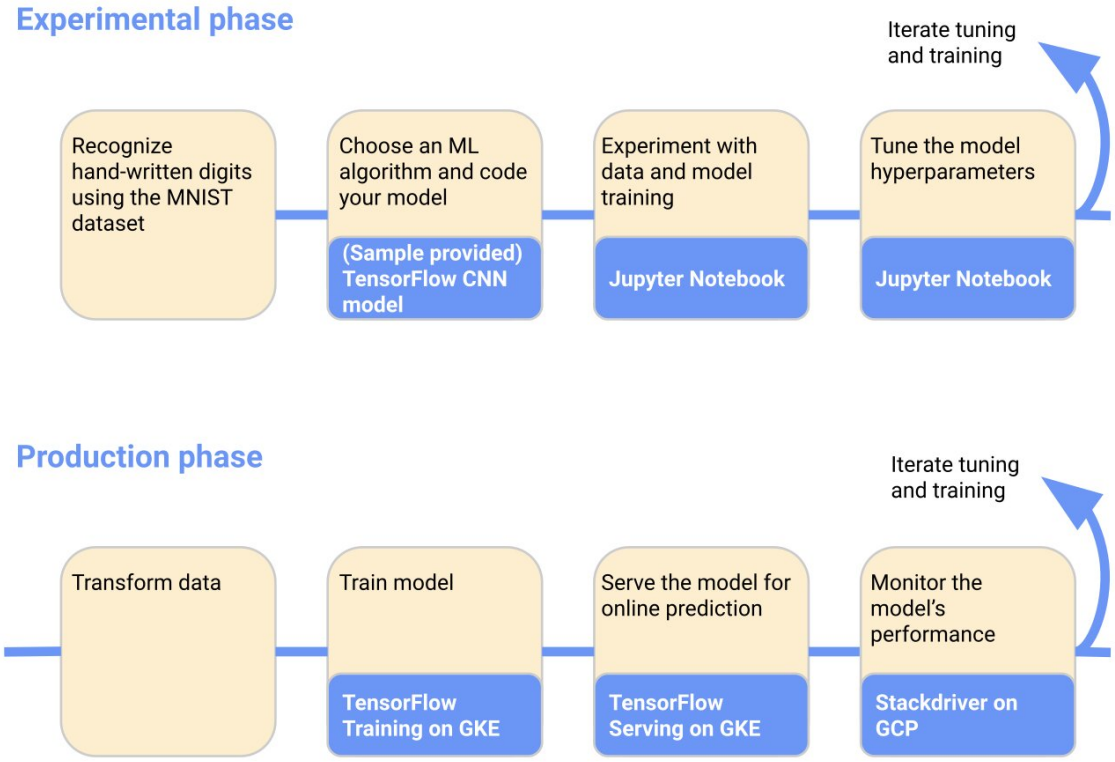

Obr. 2.2: Pracovné postupy platformy Kubeflow [22]

2.2 MiniKF

Je softvér, vyvinutý spoločnosťou Arrikto, a to kombináciou viacerých služieb a nástrojov potrebných na spustenie úloh strojového učenia lokálne alebo vzdialene na platforme Kubernetes. Skladá sa z nástroja minikube na spustenie lokálnej platformy Kubernetes, samotného Kubeflow a platformy Rok, ktorá umožňuje spúšťanie stavových kontajnerov cez rýchle lokálne úložisko NVMe. MiniKF je lokálne nasadenie Kubeflow, ktoré je možné nainštalovať v priebehu minút. Po niekoľkých kliknutiach je možné začať experimentovať a dokonca spúšťať Machine Learning Pipelines.

Pred inštaláciou je potrebné nainštalovať VirtualBox a Vagrant. Je to softvér na vytváranie a udržovanie prenosných prostredí. Pre lokálne spustenie MiniKF je potrebné spĺňať minimálne požiadavky pre operačnú pamäť minimálne 12 GB, 3 jadra procesora a 50 GB voľného miesta na disku. Na operačnom systéme nezáleží, pretože je ho možné virtualizovať na rôznych operačných systémoch napríklad ako je Linux, macOS a Windows.

Inštalácia prebieha jednoducho a pozostáva z dvoch príkazov. Prvým príkazom sa stiahne konfiguračný súbor alebo obraz do daného priečinka a inicializujeme virtuálny počítač.

```
$ vagrant init arrikto/minikf
```

Druhým príkazom sa zapne virtuálny počítač a spustí sa konfiguračný súbor.

```
$ vagrant up
```

Kubeflow je poháňaný prostredníctvom Kubernetes na tomto virtuálnom počítací. Ak je virtuálny počítač pripravený spusti sa na ňom skript a následne je možné sa pripojiť cez internetový prehliadač na adrese 10.10.10.10 k danému počítaču, kde sa spustí nástroj, ktorý developuje serie softvérových balíčkov potrebných na spustenie Kubeflow. Po reštartovaní počítača sa dáta nestratia, stačí zopakovať postup a je možné sa vrátiť k začatej práci.

2.3 Charmed

Pri developovaní Kubeflow sa pri tomto spôsobe využíva Juju Charm. Juju Charm je bezplatný aplikačný nástroj na modelovanie aplikácii s otvoreným zdrojovým kódom vyvinutý spoločnosťou Canonical, je známy aj ako štruktúrovaný balík konfiguračných súborov YAML a skriptov pre softvérový komponent, ktorý umožňuje Juju nasadiť a spravovať softvérový komponent ako službu podľa osvedčených postupov. Poskytuje centrálny pohľad na operátorov Kubernetes v nasadení, konfigurácií, rozsahu a stavu každého z nich a integračných liniek medzi nimi. Sleduje potenciálne aktualizácie a inovácie pre každého operátora a koordinuje tok udalostí a správ medzi operátormi.

Tento spôsob je vhodný najmä pre používateľov s operačným systémom Ubuntu. Samozrejme ho je možné použiť aj na iných operačných systémoch použitím virtualizácie, odporúča sa využiť Multipass, nenáročného správcu virtuálnych počítačov Ubuntu. Poskytuje virtualizáciu využitím Hyper-V alebo VirtualBoxu. Minimálne požiadavky závisia od verzie Kubeflow a to pri verzii full sú väčšie, minimálne 16 GB operačnej pamäte a 60 GB voľného miesta na disku. Full verzia poskytuje všetky služby napríklad Katib a Jupyter Notebooks. Verzia s označením lite bola vytvorená pre používateľov, ktorí pracujú v prostredí s obmedzenými zdrojmi a mal by fungovať dobre pri 8 GB operačnej pamäte a 50 GB dostupných na disku. Zachováva užívateľsky dashboard, ktorý je vhodný najmä pre začiatočníkov s lepšou interakciou. Tento balík je orientovaný najmä na nasadenie na systémoch ako notebook. Poslednou a najľahšou verziou je edge, ktorá neobsahuje dashboard a je vhodná pre tých, ktorí vyžadujú vlastných operátorov alebo pre zariadenia so slabšími výkonom. Na spustenie postačuje 4 GB operačnej pamäte. Pri každej verzii sú potrebné 2 jadra procesora. Je možné tieto verzie aj editovať,

ak neobsahujú niečo potrebné a to upravením YAML súboru.

Prvým krokom je nainštalovať Multipass, ak postup sa vykonáva na zariadení, ktorý ma operačný systém iný ako Ubuntu. Pre správne fungovanie sa využíva MicroK8s pre spravovanie klastra s 1.21 verziou Kubernetes. Je dostupná aj novšia verzia s označením 1.22, ktorá zatiaľ nepodporuje Kubeflow. Aby ďalšie príkazy fungovali bez použitia sudo je treba pridať používateľa do skupiny. Ak je Kubernetes pripravený, dostupné sú viaceré služby. Aby sa navzájom našli aplikácie, úložisko, prístup ku komponentom Kubeflow a aplikácii na vyrovnávanie záťaže MetalLB je nutné pridať DNS službu. Pred ďalšími krokmi sa kontroluje, či boli služby povolené. Pre developovanie Kubeflow platformy je nevyhnutný Juju nastroj. Jeho inštalácia je pomerne jednoduchá, pretože sa inštaluje z balíka využitím systému snap na spravovanie balíčkov. Spustenie príkazu na nasadenie ovládača Juju do Kubernetes pre ovládanie komponentov Kubeflow a odporúča sa nastaviť špecificky model. Po Juju nasleduje proces nasadenia Kubeflow a je treba vyčkať pokiaľ sa jednotlivé aplikácie a komponenty pripravia a budú môcť medzi sebou komunikovať. Pre prístup k dashboardu nakonfigurovanie niektorých komponentov je nevyhnutné s povolenou adresou URL. K dispozícii je aj možnosť nastavenia mena a hesla. Na záver je možné zobraziť dashboard v prehliadači s URL, ktorú sme nakonfigurovali. Ak sa využíva Multipass pre získanie prístupu je vhodné vytvoriť pripojenie použitím SSH so zapnutým SOCKS proxy.

2.3.1 Pripojenie strojov do klastra

Pridanie viacero uzlov (strojov) do klastra Kubernetes znamená, že pracovné zaťaženie môže byť rozdelené medzi rôzne uzly, ktoré sa môžu škálovať podľa ich špecifického zaťaženia. Nasadenia viacerých klastrov sú rozdelené do viacerých uzlov a škálujú sa podľa zaťaženia konkrétneho klastra. Čím drasticky znižuje spotrebu zdrojov jedného uzla a vedie k menšiemu zaťaženiu backendových služieb, ako sú databázy. Na rozdiel od modelu s jedným klastrom, prevádzkovanie v pracovných zaťažení poskytuje tvrdú úroveň izolácie. Riziko vzájomnej interakcie aplikácií alebo aplikácií s viacerými prostrediami, neúmyselným spôsobom je výrazne nižšie. Poskytuje lepši výkon poprepájaním strojov, ktorý je veľmi dôležitý pri strojovom učení. V tomto prípade je podstatnejší viacuzlový klaster než jednouzlový, najmä kvôli tomu, ak niektorý z hlavných uzlov zlyhá, ostatné uzly udržia klaster v prevádzke. Preto je vhodné vytvorenie viacuzlového klastra pripojením ďalších uzlov.

Postup je odlišný len na základe operačných systémov v ktorých sa bude pripájanie vykonávať. Požiadavky podľa oficiálnej dokumentácie sú nasledovné:

- Každý uzol v klastri by mal mať aspoň 2GB pamäte RAM a 2 jadra procesora.
- Samozrejmosťou je verejné alebo súkromné sieťové pripojenie pre všetky stroje v klastri.
- Názov hostiteľa a MAC adresa musia byť jedinečné.
- Funkcia swap space, ktorá slúži na rozšírenie RAM pamäte na linuxových distribúciách musí byť vypnutá.
- Každý uzol vyžaduje svoje vlastné plne izolované prostredie - samostatný fyzický počítač, virtuálny stroj, kontajner alebo iný počítač v rovnakej sieti. V jednom prostredí nie je možné spustiť dve pracovné inštancie.

Linux/Ubuntu

Ako prvé je potrebné spustiť tento príkaz na počítací, ktorý chceme aby bol riadiacim klastrom a zároveň hostiteľom riadiacej roviny Kubernetes.

```
$ microk8s add-node
```

Príkaz vygeneruje link s pokynmi na dočasnú registráciu pre nový uzol. V pokynoch sú príkazy, ktorými je možne vykonať spojenie uzla s riadiacou rovinou. Jeden z týchto príkazov sa spúšťa na stroji, ktorý chceme spojiť s uzlom, na ktorom bol spustení predošli príkaz. Proces pripojenia trvá niekoľko sekúnd. Pokyny su názorne ukázané na nasledujúcom obrázku.

```
From the node you wish to join to this cluster, run the following:
microk8s join 147.232.205.160:25000/7d99baead31ab6272b0df558db18a284/6d88dcf82beb

If the node you are adding is not reachable through the default interface you can use one of the following:
 microk8s join 147.232.205.160:25000/7d99baead31ab6272b0df558db18a284/6d88dcf82beb
 microk8s join 10.106.239.1:25000/7d99baead31ab6272b0df558db18a284/6d88dcf82beb
```

Obr. 2.3: Príkazy na pripojenie stroja do klastra

Po pridaní uzla je možné hostiť pody na viacerých strojoch. Všetky dostupné uzly sa zobrazujú spustením príkazu:

```
$ microk8s kubectl get nodes
```

Windows Server 2019 alebo novší

Pre zlúčenie stroja s operačným systémom Windows je dôležitý Docker na správu kontajnerov a pripravený klaster s Calico CNI. Je to sieťovo kontajnerové rozhranie označované ako CNI, ktoré rieši množstvo sieťových požiadaviek napríklad

komunikáciu medzi kontajnermi alebo externými službami. Zároveň sa vyžaduje aj inštalácia calicoctl, nástroj príkazového riadka pre spravovanie Calico a vykonávanie administratívnych funkcii.

Pre prístup do klastra sa vyžaduje kópia súboru kubeconfig. Pre pody na Windowse musí byť strictaffinity nastavená na hodnotu ako pravdivá, aby sa zabránilo požičiavaniu IP adries z uzlov Windowsu. Vhodné je sa ubezpečiť aká verzia Kubernetes je nasadená v klastri.

Ďalším krokom je inštalácia komponentov na stroji s operačným systémom Windows pomocou prostredia PowerShell spustený ako správca. Inštalácia pozostáva z vytvorenia priečinka, do ktorého uložíme predošlú kópiu súboru kubeconfig, inštalácie systému Calico a spustenia služby Kubernetes.

2.3.2 Odpojenie stroja z klastra

Zmazanie stroja z klastra je jednoduché a uskutočňuje sa pomocou dvoch príkazov. Príkazy sa použijú na stroji, ktorý ma byť odstránení z klastra.

Microk8s reštartuje riadiacu rovinu na uzle, ktorý sa ma vymazať. Tým obnoví operácie a stane sa osobitným klastrom. V pôvodnom klastri sa označí ako nedostupný a nebudú sa naň nasadávať nove operácie.

```
$ microk8s leave
```

Pre úplne vymazanie stroja zo zostávajúcich uzlov sa používa nasledujúci príkaz s jeho IP adresou:

```
$ microk8s remove-node <node_IP>
```

2.3.3 Podpora grafickej karty

Implementovanie grafickej karty do klastra Kubernetes je veľkou výhodou najmä kvôli výraznému skráteniu času na riešenie náročno výpočtových operácií. Je veľkou výhodou pri strojovom učení. Pridanie grafickej karty vykonáme prostredníctvom tohto príkazu.

```
$ microk8s enable gpu
```

Pre pridanie grafickej karty je potrebné splniť nasledujúce body:

- Platforma Kubeflow verzia full alebo lite je spustená v Kubernetes klastri.
- Je dostupné pripojenie na internet.
- Bolo uskutočnené prihlásenie prostredníctvom Kubeflow dashboardu.

- V hardvérovom vybavení je dostupná grafická karta od spoločnosti AMD alebo NVIDIA.

Ak je grafická karta povolená a pridaná do klastra niektoré pracovné úlohy môžu ju požadovať nastavenim limitu napríklad ako nvidia.com/gpu: 1.

2.4 Pipelines

Tento spôsob je vhodný, vtedy ak je žiadaná práca výhradne s Kubeflow pipelines. Cieľom je nasadiť pipelines na lokálnom klastri. Na nasadenie nie sú nutné žiadne virtualizačné programy a postup je v celku jednoduchý, pretože sú tým výnimočne. Kubeflow pipelines sú známe kontajnerizáciou, čo znamená, že bude sa používať Docker na vytváranie kontajnerov. Požiadavky na spustenie nie sú náročne, pre operačnú pamäť si vyžadujú minimálne 8 GB a 2 jadra procesora. Nástroj kind je kľúčový, slúži na vytvorenie lokálneho Kubernetes klastra využitím Dockera. Taktiež by bolo dobre poznamenať, že Docker vyžaduje Windows Subsystem for Linux (WSL), ktorý slúži pre natívny beh linuxových spustiteľných súborov v prostredí Windows. Pre správny postup inštalácie sa požaduje aj kubectl, ktorý sa používa na komunikáciu s klastrom vyžitím príkazového riadka a Git.

Na začiatok je potrebné nainštalovať nástroj kind. Inštalácia na operačnom systéme Windows je veľmi jednoduchá a pozostáva z niekoľko príkazov, pripadne je možné použiť Chocolatey, ktorý je vhodný na inštaláciu balíčkov na systéme Windows. Ďalším krokom je vytvorenie klastra príkazom:

```
$ kind create cluster
```

Kind spusti klaster Kubernetes pomocou vopred vytvoreného obrazu. Samozrejmosťou je použitie vlastného obrazu. Nasadenie pipelines sa vykoná spustením príkazov, ktoré stiahnu všetko potrebné z gitu a treba počkať niekoľko minút pokiaľ prebehne nasadenie všetkých komponentov potrebných pre pipelines a následne posledným krokom je presmerovanie portov. Po presmerovaní je Kubeflow dostupný otvorením internetového prehliadača na adrese lokálneho počítača.

2.5 Kubeadm

Pri tomto postupe sa využíva nástroj Kubeadm, ktorý bol zavedený pre vytváranie Kubernetes klastrov. Je vyvíjaný oficiálnou komunitou Kubernetes. Poskytuje

minimalisticky systém, veľmi dobru portabilitu a lokálne nasadenie na strojoch, ako sú napríklad notebook, Raspberry PI a podobne. Znižuje zložitosť a uľahčuje nasadenie použiteľného klastra Kubernetes. Minimálne požiadavky pre funkčný beh Kubernetes sú 2 GB operačnej pamäte a dve jadra procesora pre jeden stroj. V prípade riešeného problému tejto bakalárskej práce sa vyžaduje kvôli nasadeniu Kubeflow viac zdrojov. Záleží to od faktorov ako počet komponentov, ktoré sú požadované, koľko strojov je pripojených v klastri a s akými zdrojmi. Pre vytváranie kontajnerov nasadenie pozostáva aj z inštalácie vhodnej kontajnerovej služby ako je Docker.

Inštalácia je vykonávaná na linuxovej distribúcii. Pred nastavením klastra prostredníctvom Kubeadm je potrebné povoliť prenos cez firewall prostredníctvom IPtables. Funkcia Swap je aj v tomto spôsobe zakázaná. Základnou požiadavkou je nejaký obraz kontajnera. Na výber sú viaceré služby ako containerd, CRI-O alebo Docker. Po úspešnom nastavení je dôležité povoliť služby využívajúce kontajnerizáciu v systéme. Nutné je konfigurovať Kubeadm, Kubelet a Kubectl na verziu 1.21, keďže Kubeflow je do tejto verzie podporovaný a musí sa striktne dodržať. Pre prevenciu, aby sa programy neaktualizovali sa musia označiť ako hold, čo zabraní samovoľnému aktualizovaniu na novšiu verziu. Nasleduje inicializácia klastra na počítací prostredníctvom Kubeadm, ktorý bude riadiacou rovinou v platforme Kubernetes. Po úspešnej inicializácii Kubeadm sa vypíše výstup s umiestnením súboru kubeconfig, ktorý využíva Kubectl na interakciu s klastrom a príkaz join s tokenom. Je dobré ho niekde uchovať alebo neskôr znova vypísať, pretože je potrebný pri pridávaní stroja. V predvolenom nastavení sa pody nenaplánujú na hlavnom uzle. Hlavný uzol sa môže použiť na nasadzovanie podov, ak sa označí ako pracovný uzol. Kubeadm nenakonfiguruje žiadny sieťový doplnok. Pre správne fungovanie sa nastavuje sieťový doplnok ako Calico.

Ak je všetko dobre nastavené, overiť sa to da prostredníctvom príkazu Kubectl na vypísanie počítačov v klastri, či je daný poctiac pripravený. Počítač musí byť v stave Ready, čo znamená, že je pripravený na ďalšie kroky nasadzovania. Vhodné je aj nasadenie UI dashboardu pre lepšiu interakciu používateľa s platformou.

Spustenie Kubeflow platformy sa realizuje manuálnou inštaláciou manifestov. Existujú aj rôzni distribútori ako Google, Amazon alebo IBM. Ich služby a ich realizácia je jednoduchšia, sú však spoplatnené. Kubeflow vyžaduje nastavenie Kubernetes s prednastaveným StorageClass a nástroja Kustomize, ktorý slúži na prispôsobovanie objektov pomocou jeho Kustomize súborov. Kubeflow s verziou 1.5 zatiaľ nie je kompatibilný s najnovšou verziou Kustomize, preto musí byť verzia 3.2. Do počítača si naklonujeme oficiálny git repozitár od spoločnosti Ku-

beflow. Sú dva spôsoby implementovania manifestov použitím jedného, kde sa použijú všetky existujúce komponenty alebo pomocou viacerých príkazov a to vlastným výberom komponentov, ktoré sa vyžadujú. Po niekoľkých minútach sú všetky komponenty pripravené. A posledným krokom ostáva zapnutie Dashboardu, kde používateľ môže naplno využívať komponenty.

2.5.1 Pripojenie strojov do klastra

Implementácia a požiadavky sú podobné ako pri predchádzajúcom pripájaní strojov do klastra využitím Charmed Kubeflow nasadenia.

Linux/Ubuntu

Pre pripojenie linuxového stroja je nutné na ňom zopakovať niektoré inštalačné postupy, ktoré boli vykonané pri konfigurácii Kubernetes klastra:

- Povolit prenos cez Firewall pomocou IPtables
- Zákaz funkcie Swap
- Docker
- Kubeadm, Kubelet, kubectl

Po týchto krokoch je možné použiť hore spomínaný príkaz join na pripojenie stroja do klastra.

Windows Server 2019 alebo novší

Spustenie a spojazdnenie komponentov pre platformu Kubernetes na Windowse je obťažnejšie a môže byt problémové. Pre pridanie stroja s operačným systémom Windows do klastra, ktorý beží na Linuxe je na ňom treba vykonať doplnkové akcie.

Na stroji, ktorý nesie označenie hlavnej roviny sa stiahne Flannel manifest, v ktorom sa upravia čísla portov, aby Linux spolupracoval s Flannelom v systéme Windows. Flannel sa používa na priraďovanie IP adries kontajnerom a pre komunikáciu medzi nimi. Editovanú konfiguráciu je možné aplikovať do klastra. Treba však aj tu poznamenať dodržanie verzii, aby súladili s verziou Kubernetes spustenej na klastri. Po chvíli sa vytvoria sieťové Flannelové moduly.

Na stroji s Windowsom, ktorý sa pridáva do klastra vykonáme inštaláciu Dockera s verziou Engine Enterprise a povolenie funkcie Hyper-V. Na rade sú Wins,

Kubelet a Kubeadm, ktoré musia mať rovnakú verziu ako klaster Kubernetes. Ako posledná akcia, ktorá by sa mala vykonať je použitie príkazu join.

2.5.2 Odpojenie stroja z klastra

Odstránenie prebieha pomocou nástroja kubectl, použitím nasledovných príkazov na riadiacej rovine.

Označenie stroja ako neplánovateľný, aby sa zamedzilo pridávaniu nových podov.

```
$ kubectl cordon <node_ID>
```

Bezpečné odstránenie všetkých podov z uzla pred odstránením. Vysťahovanie kontajnerov, aby sa mohli ukončiť pody na stroji, ktorý sa odstraňuje. Ak všetko prebehne v poriadku, znamená to, že všetky pody boli bezpečne odstránené alebo presunuté.

```
$ kubectl drain <node_ID>
```

Následne je možné prejsť k odstráneniu všetkých údajov o danom stroji z klastra.

```
$ kubectl delete node cmp<node_ID>
```

2.5.3 Podpora grafickej karty

Pridanie grafickej karty sa sprostredkuje prostredníctvom grafických kariet od spoločnosti NVDIA a AMD. Podmienkou je mať nainštalované ovládače od grafických kariet. Operácia aplikovania grafickej karty je vykonaná prostredníctvom príkazu s manifestom vo forme YAML súboru podľa toho o akú grafickú kartu ide.

```
$ kubectl create -f <manifest>
```

Ak sa jedná o grafickú kartu spoločnosti NVIDIA je nutné spraviť dodatočné opatrenia:

- Vopred nainštalovaný nástroj pre kontajnery nvidia-docker s verziou 2.0.
- Kubelet musí používať Docker ako svoj kontajnerový obraz.
- Nvidia-container-runtime nakonfigurovaný ako predvolený runtime pre Docker namiesto runc.

3 Výsledky testovania technologií

V tejto kapitole je zhrnuté porovnanie testovaných scenárov a postupov na nasadenie platformy Kubernetes a Kubeflow, ktoré sa využívajú na riešenie problémov strojového učenia. Priblížené sú problémy, ktoré sa vyskytovali pri uplatňovaní týchto plánov, ich zvládnutie, objektívne vyhodnotenie týchto technológii a vyzdvihnutie najlepšieho spôsobu.

Testovanie prebiehalo na serveroch od portálu CLOUD TUKE s operačnými systémami Windows server 2019 a Ubuntu 20.04 Desktop s nasledovnými parametrami:

- Procesor: **Intel(R) Xeon(R) CPU E5-2670 v3 @ 2.30GHz**
- Počet jadier: **8**
- Veľkosť operačnej pamäte RAM: **16 GB**
- Veľkosť pamäťového úložiska: **70 - 100 GB**

Pre menej náročné scenáre bol tiež využívaný osobný laptop s operačným systémom Windows 10:

- Procesor: **Intel(R) Core(TM) CPU i5-8265U @ 1.60GHz**
- Počet jadier: **4**
- Veľkosť operačnej pamäte RAM: **8 GB**
- Veľkosť pamäťového úložiska: **256 GB**

3.1 Zhodnotenie implementácii a problémov

MiniKF

Tento spôsob je veľmi jednoduchý a rýchly k nasadeniu na lokálnom počítací. Najväčšou výhodu ma to, že používateľ nemusí riešiť kroky k spusteniu platforiem.

Všetko je predpripravené a používateľ spusti pripravený obraz na virtualizácii. Nevýhodou je v takom prípade, že podpora grafickej karty a funkcia pre pripájanie ďalších počítačov nie je implementovaná. Vyžaduje sa zapnutie virtualizácie alebo technológie Hyper-V. Obsahuje všetky komponenty na riešenie strojových úloh k experimentovaniu a ladeniu parametrov. Tým, že obsahuje veľa modulov sa odzrkadľuje na systémových požiadavkách, ktoré sú relatívne v norme na spustenie, na stroji s bežným cenovo nenáročným hardvérovým vybavením.

Pri testovaní vznikali problémy najmä po zapnutí Vagrantu, kedy bol virtuálny stroj vo fáze spusteného skriptu. Stroj zamrzol alebo sa samovoľne vypol. Navádzalo to k novému opakovanému štartu virtuálneho stroja. Riešením bolo pridanie viacero jadier pre daný stroj. Dalo sa to vykonať spustením virtualizácie VirtualBox v nastaveniach vytvoreného stroja, keďže ju Vagrant prioritne využíva.

Adekvátny je pre začiatočníkov, ktorí nemajú a nemali žiadnu skúsenosť s danou platformou. Používateľ sa tak môže rýchlo a efektívne zoznámiť najmä so systémom Kubeflow a jeho komponentami a nemusí riešiť spúšťanie a nasadzovanie týchto technológií.

Výhody:

- Nenáročný na spustenie.
- Vhodný pre začiatočníkov.
- Multiplatformový.

Nevýhody:

- Neexistuje možnosť pridania strojov do klastra.
- Nepodporuje GPU.
- Presne dané komponenty.

Charmed

Pri Charmed je veľkou výhodou, že poskytuje na výber viacero verzií systému Kubeflow. Poskytuje tri verzie s rôznymi hardvérovými požiadavkami a komponentami. Je vhodné aj pripomenúť, že tieto verzie sa dajú upravovať podľa predstav používateľa a nie je nutné nasadzovať všetky komponenty. Vytvorenie klastra je rýchle a jednoduché, lebo je sprostredkované nástrojom Microk8s. Menšou nevýhodou je, že podporuje len operačný systém Ubuntu. Je to však zohľadnené pri pripájaní strojov. Pripojiť je možné počítače s operačným systémom Windows a samozrejmosťou je aj Linux.

Microk8s sa môže aj virtualizovať, ale to sa neodporúča na základe testov, ktoré boli vykonané. Nasadenie systému Kubeflow bolo úspešne, ale nastaval po-

tom problém s pripájaním ďalších strojov do klastra z neznámeho dôvodu.

Je určený pre používateľov s mierne pokročilými znalosťami v danej oblasti, ktorí chcú mať plne funkčný a vysoko dostupný klaster s pripojenými strojmi a využitím grafickej karty.

Výhody:

- Spĺňa všetky požiadavky pre plne funkčný klaster.
- Možnosť prispôsobenia komponentov.
- Rýchle a funkčné nasadenie klastra.

Nevýhody:

- Podpora len pre linux.
- Hárdverovo náročnejší.

Pipelines

Pipelines obsahujú základné komponenty pre beh komponentu s názvom Pipelines. Pomocou nástroja kind sa spustí minimalistický klaster a nasadí sa Kubeflow. Nevýhodou je, že nepodporuje GPU. Slúži na lokálne nasadzovanie na osobných počítačoch pre rýchle testovanie. Je vhodný pre väčšinu známych operačných systémov.

Pri testovaní nenastali žiadne problémy a je určený pre začiatočníkov alebo mierne pokročilých, ktorí sa chcú zoznámiť s najdôležitejším komponentom zo systému Kubeflow.

Výhody:

- Stabilný.
- Nemá náročné požiadavky.
- Vhodný pre lokálne nasadenie.

Nevýhody:

- Chýba možnosť pridania ďalších modulov.
- Nespĺňa všetky požiadavky pre plne funkčný klaster.

Kubeadm

Kubeadm poskytuje plnohodnotné vytvorenie klastra potrebného na implementovanie Kubeflow so všetkými jeho komponentami. Je podobný predošlému spôsobu Charmed s tým rozdielom, že Kubeadm poskytuje rozšírenejšie nastavenia. Pri spojazdnení tohto systému je v porovnaní s Charmed zložitejší, ale zase na druhej strane ponuka viac možnosti. Veľmi výhodný je v tom, že nemá ná-

ročné systémové požiadavky. Pri nasadávaní sa môžu komponenty prispôsobovať podľa požiadaviek, ktoré ma užívateľ. Samozrejmosťou je podpora GPU od NVIDIA a AMD.

Nastavali mierne problémy, ktoré bolo treba riešiť. Opakovaným problémom sa stávalo, že bola nainštalovaná iná verzia komponentov pre Kubernetes, pretože Kubeflow je spustiteľný len na verzii 1.21. Po inicializovaní klastra bol predvolene nastavený zákaz plánovania podov na riadiacej rovine. Tento problém bol vyriešený príkazom na pridanie vlastnosti ako majú pracovné stroje. Pri pripájaní stroja so systémom Windows sa Docker odpájal a bolo ho potrebné reštartovať.

S nasadením si poradí už pokročilejší užívateľ, ktorý je zapojený do danej problematiky.

Výhody:

- Vyhovujúci produkčnému použitiu.
- Možnosť Kubernetes dashboardu.
- Rozšírené nastavenia.

Nevýhody:

- Nevhodný pre začiatočníkov.
- Podporuje len Linux.

3.2 Výber vhodnej technológie

Pri porovnaní implementácii MiniKF a Pipelines sa ukázalo, že obidve sú primerané na lokálne testovanie platforiem pre používateľov, ktorí sa chcú zoznámiť s platformami alebo pre nasadenie na strojoch so slabším hardvérovým vybavením. Podstatný rozdiel medzi nimi je v obsahu komponentov platformy Kubeflow. Nepodporujú GPU a ani zlučovanie pridávnych strojov. Na základe týchto vlastností, nie sú vhodné na riešenie problematiky daného problému tejto práce.

Charmed a Kubeadm si sú veľmi podobné. Ponúkajú pripojenie strojov do klastra a podporu GPU. Rozdielne sú v systémových požiadavkách, kde Kubeadm je menej záťažový pre stroje. Exceluje aj vďaka ponúkaným rozšíreným nastaveniam, ktoré sú náročnejšie na konfiguráciu než pri Charmed, kde sú jednotlivé prvky zjednodušené a viac pochopiteľne. Na základe zhodnotenia, ktoré bolo vykonané, vyniká Kubeadm.

Podľa týchto porovnaní je na riešenie úloh strojového učenia spôsobilé zriadenie implementácie Kubeadm. Na následnej tabuľke sú stručne opísane parametre a vybavenosť implementácií.

	Systémové požiadavky			Operačný systém			Komponenty KF				Pripojenie strojov	GPU
	CPU	RAM	HDD	Windows	Linux	MacOS	Notebooks	Pipelines	Katib	Dashboard		
MiniKF	3	12GB	50GB	✓	✓	✓	✓	✓	✓	✓	✗	✗
Charmed full	2	16GB	60GB	✗	✓	✗	✓	✓	✓	✓	✓	✓
Charmed lite	2	8GB	50GB	✗	✓	✗	✓	✓	✗	✓	✓	✓
Charmed edge	2	4GB	10GB	✗	✓	✗	✗	✗	✗	✗	✓	✗
Pipelines	2	8GB	20GB	✓	✓	✓	✗	✓	✗	✓	✗	✗
Kubeadm	2	12GB	50GB	✗	✓	✗	✓	✓	✓	✓	✓	✓

Tabuľka 3.1: Požiadavky a funkcie implementácií.

4 Záver

V tejto bakalárskej práci, bolo prvým krokom analyzovanie a stručný opis platformy Kubernetes, ktorá sa vzhľadom na problematiku tejto práce využíva na riešenie úloh strojového učenia. Čitateľ je oboznámený s výhodami tejto platformy, ktoré ponúka. Za dôležité sa považoval opis a rozdelenie architektúry jednotlivých komponentov, z ktorých je platforma zlozená. Sú často spomínane v ďalších kapitolách, preto je vhodné sa s nimi zoznámiť. Porovnané sú niektoré známe nástroje, ktoré sú dostupné na internete na vytvorenie klastra Kubernetes. Kontajnerizácia je neodmysliteľnou súčasťou správnej funkčnosti tejto platformy. Poukazuje na to, aké má výhody oproti virtualizačným systémom a preto je adekvátna na riešenie daného problému.

Na riešenie problémov strojového učenia je najlepším a zároveň najznámejším systémom Kubeflow, slúžiaci na nasadenie pre platformu Kubernetes, ktorý obsahuje všetko pre obľúbencov a inžinierov strojového učenia. Súčasťou je charakteristika dôležitých časti a pracovných postup pre predstavu o chode tohto systému. Opísane sú postupy na vytvorenie testovacieho prostredia využívajúce tento systém, pre spúšťanie úloh naprogramovaných v jazyku Python. Používateľ je bližšie informovaný o krokoch a postupoch, ktoré sú žiadane a aké požiadavky tento scenár nasadenia vyžaduje od hardvérových až systémových nárokov. V prípade, že scenár podporuje GPU a viacuzlový klaster pri danom scenári je pripojenie strojov alebo podpora grafickej karty.

Na záver sú porovnané a zhodnotené tieto nasadenia s odôvodneným výberom najlepšieho scenára pre splnenie požiadaviek tejto práce. Výsledkom je vytvorený Kubernetes klaster s pripojenými strojmi umožňujúci nasadenie úloh strojového učenia. Obsahuje aj manuál na vytvorenie a pripojenie viacerých počítačov do platformy Kubernetes a tiež manuál na implementáciu a nasadenie Python zdrojových kódov spustiteľných na platforme Kubernetes.

Literatúra

1. IBM, Cloud Education. *KUBERNETES: FEATURES AND BENEFITS* [online] [cit. 2021-10-20]. Dostupné z: https://www.criticalcase.com/blog/kubernetes-features-and-benefits.html.
2. KUBERNETES, kubernetes.io. *What is Kubernetes?* [online] [cit. 2021-10-20]. Dostupné z: https://kubernetes.io/docs/concepts/overview/what-is-kubernetes.
3. IBM, Cloud Education. *What are microservices?* [online] [cit. 2021-10-20]. Dostupné z: https://www.ibm.com/cloud/learn/microservices.
4. BYTEMARK, docs.bytemark.co.uk. *Kubernetes Terminology: Glossary* [online] [cit. 2021-10-20]. Dostupné z: https://docs.bytemark.co.uk/article/kubernetes-terminology-glossary.
5. WITHERS, John. *What Is Kubernetes? An Introduction to the Wildly Popular Container Orchestration Platform* [online] [cit. 2021-10-20]. Dostupné z: https://newrelic.com/blog/how-to-relic/what-is-kubernetes.
6. GUPTA, Gaurav. *Components of Kubernetes Architecture* [online] [cit. 2021-10-20]. Dostupné z: https://kumargaurav1247.medium.com/components-of-kubernetes-architecture-6feea4d5c712.
7. RED HAT, redhat.com. *What is etcd?* [online] [cit. 2021-10-25]. Dostupné z: https://www.redhat.com/en/topics/containers/what-is-etcd.
8. AMAZON WEB SERVICES, docs.aws.amazon.com. *Managing the kube-proxy add-on* [online] [cit. 2021-10-20]. Dostupné z: https://docs.aws.amazon.com/eks/latest/userguide/managing-kube-proxy.html.
9. RANCHER, rancher.com. *K3s - Lightweight Kubernetes* [online] [cit. 2021-10-26]. Dostupné z: https://rancher.com/docs/k3s/latest/en/.
10. MICROK8S, microk8s.io. *MicroK8s documentation* [online] [cit. 2021-10-28]. Dostupné z: https://microk8s.io/docs.

11. CITRIX SYSTEMS, citrix.com. *What is containerization?* [online] [cit. 2021-10-30]. Dostupné z: https://www.citrix.com/solutions/app-delivery-and-security/what-is-containerization.html.

12. VMWARE, vmware.com. *Why use containers vs. VMs?* [online] [cit. 2021-11-05]. Dostupné z: https://www.vmware.com/topics/glossary/content/container-orchestration.html.

13. RICHARDSON, Chris. *Pattern: Microservice Architecture* [online] [cit. 2021-11-05]. Dostupné z: https://microservices.io/patterns/microservices.html.

14. MICROSOFT, docs.aws.microsoft.com. *Containers vs. virtual machines* [online] [cit. 2021-11-09]. Dostupné z: https://docs.microsoft.com/en-us/virtualization/windowscontainers/about/containers-vs-vm.

15. AQUA SECURITY SOFTWARE, aquasec.com. *Docker Containers vs. Virtual Machines* [online] [cit. 2021-11-09]. Dostupné z: https://www.aquasec.com/cloud-native-academy/docker-container/docker-containers-vs-virtual-machines/.

16. WEAVEWORKS, weave.works. *Docker vs Virtual Machines (VMs) : A Practical Guide to Docker Containers and VMs* [online] [cit. 2021-11-09]. Dostupné z: https://www.weave.works/blog/a-practical-guide-to-choosing-between-docker-containers-and-vms.

17. JELASTIC, jelastic.com. *What are Application Containers?* [online] [cit. 2021-11-09]. Dostupné z: https://docs.jelastic.com/what-are-application-containers/.

18. EXCELLA, excella.com. *Application vs System Container* [online] [cit. 2021-11-09]. Dostupné z: https://www.excella.com/insights/application-vs-system-containersv.

19. HEYER, Sascha. *Kubeflow Components and Pipelines* [online] [cit. 2021-11-30]. Dostupné z: https://towardsdatascience.com/kubeflow-components-and-pipelines-33a1aa3cc338.

20. KUBEFLOW, kubeflow.org. *Introduction to Katib* [online] [cit. 2021-11-30]. Dostupné z: https://www.kubeflow.org/docs/components/katib/overview/.

21. KUBEFLOW, kubeflow.org. *Kubeflow Operator introduction* [online] [cit. 2021-11-30]. Dostupné z: https://www.kubeflow.org/docs/distributions/operator/introduction/.

22. KUBEFLOW, kubeflow.org. *Architecture* [online] [cit. 2021-11-30]. Dostupné z: `https://www.kubeflow.org/docs/started/kubeflow-overview`.

Zoznam skratiek

GCD Greatest Common Divisor.

Slovník

Class Diagram is a type of static structure diagram that describes the structure of a system by showing the system's classes, their attributes, operations (or methods), and the relationships among objects.

Zoznam príloh

Príloha A Karel Language Reference

Príloha B CD médium – záverečná práca v elektronickej podobe,

Príloha C Používateľská príručka

Príloha D Systémová príručka

A Karel Language Reference

A.1 Karel's Primitives

- `void movek()` - Moves *Karel* one intersection forward.
- `void turn_left()` - Pivots *Karel* 90 degrees left.
- `void pick_beeper()` - Takes a beeper from the current intersection and puts it in the beeper bag.
- `void put_beeper()` - Takes a beeper from the beeper bag and puts it at the current intersection.
- `void turn_on(char* path)` - Turns *Karel* on.
- `void turn_off()` - Turns *Karel* off.

Karel's Sensors

- `int front_is_clear()` - Returns `1` if there is no wall directly in front of *Karel*. `0` if there is.
- `int right_is_clear()` - Returns `1` if there is no wall immediately to *Karel*'s right. `0` if there is.
- `int beepers_present()` - Returns `1` if *Karel* is standing at an intersection that has a beeper. `0` otherwise.
- `int facing_north()` - Returns `1` if *Karel* is facing north. `0` otherwise.
- `int beepers_in_bag()` - Returns `1` if there is at least one beeper in *Karel*'s beeper bag. `0` if the beeper bag is empty.

Misc Functions

- `void set_step_delay(int)` - Sets delay of one *Karel*'s step in miliseconds.
- `loop(int)` - Repeats *Karel*'s instruction in a loop.